Bartłomiej Przewoźniak, grupa 8ISI
Techniki kompilacji, projekt własny
Wstępna dokumentacja projektu

I. Funkcjonalność:

Wymagania funkcjonalne:
Program będzie generował pliki klas Javowych dla istniejącego opisu struktur danych zapisanego w schemacie AVRO w notacji JSON realizując następujące funkcje:

- czytanie pliku wejściowego znak po znaku,
- tworzenie tokenów zgodnych z językiem,
- sprawdzenie składni,
- budowanie drzewa obiektów,
- generowanie pliku wyjściowego.

Wymagania niefunkcjonalne:
Tekst pliku wejściowego powinien być kodowany za pomocą UTF-8.

II. Sposób uruchomienia, wejścia/wyjścia:

Rozwiązaniem zadania będzie program z interfejsem wiersza poleceń napisany w języku Java. Po uruchomieniu wpisujemy nazwę pliku wejściowego oraz pliku wyjściowego. Program przyjmuje na wejściu jeden plik tekstowy w notacji JSON, zaś na wyjściu zwraca wygenerowany plik zawierający opis klasy w języku Java.

III. Gramatyka i struktury:

Notacja JSON jest prostym formatem wymiany danych.

Tokeny:

Nazwa	Wartość
LEFT_BRACE	{
RIGHT_BRACE	}
LEFT_BRACKET	[
RIGHT_BRACKET	]
COLON	:
COMMA	,
STRING	”chars”
NUMBER	0 | [1-9][0-9]*(.[0-9]+)
LITERAL	true | false | null

Składnia:

JSON powstał w oparciu o dwie struktury: obiekty oraz tablice.

Obiekt jest nieuporządkowanym zbiorem par nazwa/wartość. Opis obiektu rozpoczyna { (lewa klamra) a kończy } (prawa klamra). Po każdej nazwie następuje : (dwukropek) oraz pary nazwa/wartość, oddzielone , (przecinkiem).

```
object:
	{ }
	{ members }

members:
	pair
	pair, members

pair:
	string : value
```

Tabela jest uporządkowanym zbiorem wartości. Opis tabeli rozpoczyna znak [(lewy nawias kwadratowy) a kończy znak] (prawy nawias kwadratowy). Poszczególne wartości rozdzielane są znakiem , (przecinek).

```
array:
	[ ]
	[ elements ]

elements:
	value
	value, elements
```

Wartość to łańcuch znakowy, którego początek i koniec oznacza podwójny cudzysłów, lub liczba, lub wartość true (prawda) lub false (fałsz) lub null, lub obiekt lub tabela. Struktury te można zagnieżdżać.

```
value:
	string
	number
	object
	array
	„true”
	„false”
	„null”
```

Łańcuch znakowy jest zbiorem zera lub większej ilości znaków Unicode, opakowanym w podwójne cudzysłowy. Pojedynczy znak jest reprezentowany jako łańcuch jednoznakowy. Łańcuch znakowy JSON jest podobny do łańcucha znakowego Java.

```
string:
	„ ”
	„ chars ”

chars:
	char
	char chars

char:
	any Unicode character except " or \ or control character
```

Liczby zapisywane w formacie JSON są bardzo podobne do liczb w języku Java, poza tym wyjątkiem, że nie używa się formatów ósemkowych i szesnastkowych.

Wolne miejsce (spacje, znaki tabulatora, itp.) można wstawić między dowolną parę składowych. Poza kilkoma detalami dotyczącymi kodowania, na tym kończy się opis języka JSON.

Typy proste schematu AVRO:

Nazwa	Wartość
null	no value
boolean	a binary value
int	32-bit signed integer
long	64-bit signed integer
float	single precision (32-bit) IEEE 754 floating-point number
double	double precision (64-bit) IEEE 754 floating-point number
bytes	sequence of 8-bit unsigned bytes
string	unicode character sequence

Składnia:

JSON powstał w oparciu o dwie struktury: obiekty oraz tablice.

Obiekt jest nieuporządkowanym zbiorem par nazwa/wartość. Opis obiektu rozpoczyna **{** (lewa klamra) a kończy **}** (prawa klamra). Po każdej nazwie następuje **:** (dwukropek) oraz pary nazwa/wartość, oddzielone **,** (przecinkiem).

Wykorzystywane struktury danych:

```
enum TokenType {
	LEFT_BRACE,
	RIGHT_BRACE,
	LEFT_BRACKET,
	RIGHT_BRACKET,
	COLON,
	COMMA,
	STRING,
	NUMBER,
	LITERAL,
	EOF
};

class Token
{
	int row;
	int column;
	string value;
	TokenType tokenType;
};
```

```
enum NodeType
{
	ROOT,
	OBJECT,
	ARRAY,
	PAIR,
	NAME,
	VALUE
};

class Node
{
    string name;
    string value;
    Node parent;
    Node firstChild;
    Node nextSibling;
    NodeType nodeType;
};
```

IV. Moduły:

a) Analizator leksykalny:
   - pobiera po kolei znaki z pliku tekstowego tworząc z nich token zgodny z gramatyką i zwraca go jako wynik przekazany do parsera.

b) Analizator składniowy wraz z akcjami semantycznymi:
   - porozumiewa się z analizatorem leksykalnym, który przesyła kolejne tokeny. Na ich podstawie tworzy drzewa składające się z obiektów JsonNode.
   - sprawdza poprawność występujących pól z warunkami schematu AVRO: słowa kluczowe, typy prymitywne i złożone.

c) Generator pliku wyjściowego:
   - przekształca powstałą strukturę na plik tekstowy zawierający opis klasy w języku Java.

Drzewo dokumentu:

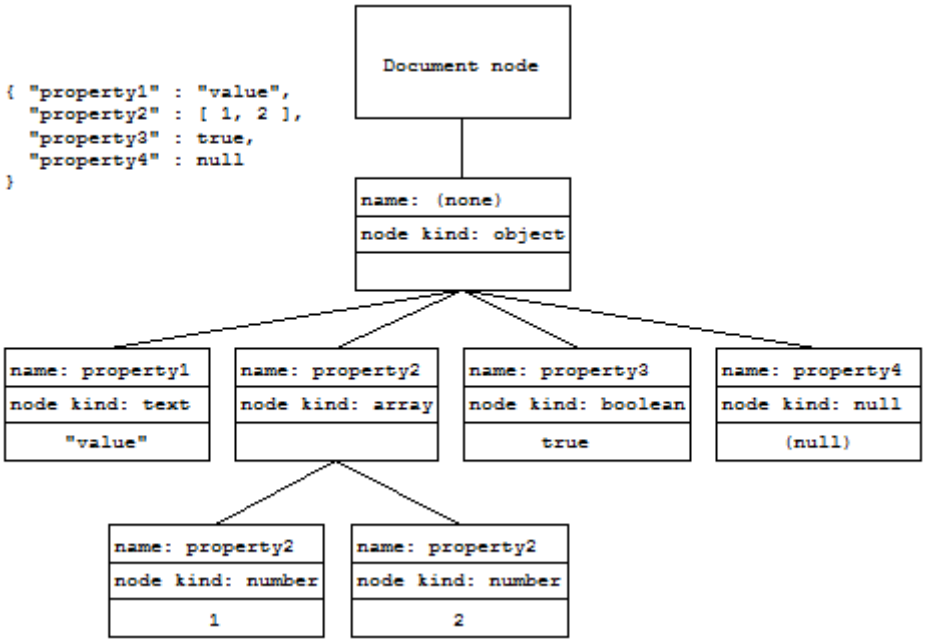

V. Obsługa sytuacji wyjątkowych:

Błędy w pliku wejściowym powodują wyświetlenie komunikatu o błędzie i przerwanie działania programu. W komunikacie o błędzie wypisuje jaki niepoprawny token otrzymaliśmy oraz miejsce w pliku (numer wiersza i numer kolumny). Przewidywane przypadki:

- InvalidStringException – konstrukcje niepoprawne leksykalnie,
- InvalidTokenException – konstrukcje niepoprawne semantycznie,
- InvalidAvroException – konstrukcje niespełniające warunków schematu AVRO,
- InvalidJavaException – konstrukcje niespełniające warunków języka Java.

VI. Przykłady testowe:

Schemat AVRO w notacji JSON:

```
{
  "type": "record",
  "name": "Movie",
  "namespace": "org.kitesdk.examples.data",
  "fields": [
    {
      "name": "id",
      "type": "int"
    },
    {
      "name": "title",
      "type": "string"
    },
    {
      "name": "releaseDate",
      "type": "string"
    },
    {
```

```
      "name": "imdbUrl",
      "type": "string"
    }
  ]
}
```

Klasa w języku Java:

```
package org.kitesdk.examples.data;

public class Movie {
    private int id;
    private String title;
    private String releaseDate;
    private String imdbUrl;

    public Movie() {}

    public Movie(int id, String title, String releaseDate, String
imdbUrl) {
        this.id = id;
        this.title = title;
        this.releaseDate = releaseDate;
        this.imdbUrl = imdbUrl;
    }

    public int getId() {
        return id;
    }

    public void setId(int id) {
        this.id = id;
    }

    public String getTitle() {
        return title;
    }

    public void setTitle(String title) {
        this.title = title;
    }

    public String getReleaseDate() {
        return releaseDate;
    }

    public void setReleaseDate(String releaseDate) {
        this.releaseDate = releaseDate;
    }

    public String getImdbUrl() {
        return imdbUrl;
    }

    public void setImdbUrl(String imdbUrl) {
        this.imdbUrl = imdbUrl;
    }

}
```

VII. Literatura:

http://www.ietf.org/rfc/rfc4627.txt - opis notacji JSON.
https://avro.apache.org/docs/current/spec.html - opis schematu AVRO.