Bartłomiej Przewoźniak, grupa 8ISI
Techniki kompilacji, projekt własny
Wstępna dokumentacja projektu

I. Funkcjonalność:

Wymagania funkcjonalne:
Program będzie generował pliki klas Javowych dla istniejącego opisu struktur danych zapisanego w schemacie AVRO w notacji JSON realizując następujące funkcje:

- czytanie pliku wejściowego znak po znaku,
- tworzenie tokenów zgodnych z notacją Json,
- sprawdzenie poprawności semantycznej pliku (z uwzględnieniem reguł Json i Avro),
- budowanie drzewa obiektów typu JsonNode,
- generowanie pliku wyjściowego – klasy Java.

Wymagania niefunkcjonalne:
Tekst pliku wejściowego powinien być kodowany za pomocą UTF-8.

II. Sposób uruchomienia, wejścia/wyjścia:

Rozwiązaniem zadania będzie program z interfejsem wiersza poleceń napisany w języku Java. Po uruchomieniu mamy wybór scenariusza: główna funkcjonalność programu, testy modułowe lub testy całościowe. Podstawowa funkcjonalność programu przyjmuje na wejściu jeden plik tekstowy w notacji JSON, zaś na wyjściu zwraca wygenerowany plik zawierający opis klasy w języku Java.

III. Gramatyka notacji JSON:

Notacja JSON jest prostym formatem wymiany danych.

- Typy proste:

Nazwa	Wartość
LEFT_BRACE	{
RIGHT_BRACE	}
LEFT_BRACKET	[
RIGHT_BRACKET	]
COLON	:
COMMA	,
STRING	”chars”
NUMBER	0 | [1-9][0-9]*(.[0-9]+)
LITERAL	true | false | null

- Typy złożone:

JSON powstał w oparciu o dwie struktury: obiekty oraz tablice.

Obiekt jest nieuporządkowanym zbiorem par nazwa/wartość. Opis obiektu rozpoczyna **{** (lewa klamra) a kończy **}** (prawa klamra). Po każdej nazwie następuje **:** (dwukropek) oraz pary nazwa/wartość, oddzielone **,** (przecinkiem).

Tablica jest uporządkowanym zbiorem wartości. Opis tabeli rozpoczyna znak **[** (lewy nawias kwadratowy) a kończy znak **]** (prawy nawias kwadratowy). Poszczególne wartości rozdzielane są znakiem **,** (przecinek).

- Składnia:

```
object:
	{ }
	{ members }

members:
	pair
	pair, members

pair:
	string : value

array:
	[ ]
	[ elements ]

elements:
	value
	value, elements
```

Wartość to łańcuch znakowy, którego początek i koniec oznacza podwójny cudzysłów, lub liczba, lub wartość **true** (prawda) lub **false** (fałsz) lub **null**. Wartością może być również obiekt lub tabela. Struktury te można zagnieżdżać.

```
value:
	string
	number
	object
	array
	„true”
	„false”
	„null”
```

Łańcuch znakowy jest zbiorem zera lub większej ilości znaków Unicode, opakowanym w podwójne cudzysłowy. Pojedynczy znak jest reprezentowany jako łańcuch jednoznakowy. Łańcuch znakowy JSON jest podobny do łańcucha znakowego Java.

Liczby zapisywane w formacie JSON są bardzo podobne do liczb w języku Java, poza tym wyjątkiem, że nie używa się formatów ósemkowych i szesnastkowych.

```
string:
```

```
      „ ”
      „ chars ”

chars:
      char
      char chars

char:
      any Unicode character except " or \ or control character
```

Wolne miejsce (spacje, znaki tabulatora, itp.) można wstawić między dowolną parę składowych. Poza kilkoma detalami dotyczącymi kodowania, na tym kończy się opis języka JSON.

IV. Gramatyka schematu AVRO:

Schemat AVRO powstał w oparciu o notację JSON.
Dla typów prostych zachodzi następujące mapowanie wartości:

AVRO type	JSON type	Przykład
null	null	null
boolean	boolean	true
int,long	integer	1
float,double	number	1.1
bytes	string	"\u00FF"
string	string	"foo"
record	object	{"a": 1}
enum	string	"FOO"
array	array	[1]
map	object	{"a": 1}
fixed	string	"\u00ff"

- Typy proste:

Nazwa	Wartość
null	no value
boolean	a binary value
int	32-bit signed integer
long	64-bit signed integer

float	single precision (32-bit) IEEE 754 floating-point number
double	double precision (64-bit) IEEE 754 floating-point number
bytes	sequence of 8-bit unsigned bytes
string	unicode character sequence

- Typy złożone:

Schemat AVRO wspiera sześć typów złożonych: record, enum, array, map, union oraz fixed.

- Składnia:

Definicje typów złożonych prezentują się w następujący sposób:

enum:

```
{
      "type": "enum",
      "name": "Suit",
      "symbols" : ["SPADES", "HEARTS", "DIAMONDS", "CLUBS"]
}
```

array:

```
{
      "type": "array",
      "items": "string"
}
```

map:

```
{
      "type": "map",
      "values": "long"
}
```

union:

```
{
      "type": "array",
      "items": ["null", "string"]
}
```

fixed:

```
{
      "type": "fixed",
      "size": 16,
      "name": "md5"
}
```

V. Mapowanie obiektów:

- Typy proste:

Schemat AVRO:	Klasa JAVA:
{ **"name":**"name",	private String name;

`"type":"string"`
`}`
	public String getName() {
	return name;
	}
	
	public void setName(String name) {
	this.name = name;
	}

- Typy złożone:

Schemat AVRO:	Klasa JAVA:

`{`
`"name":"array",`
`"type":"string",`
`"items":"string"`
`}`
	private String[]ingredients;
	
	public String[] getIngredients() {
	return ingredients;
	}
	
	public void setIngredients(String[] ingredients) {
	this.ingredients = ingredients;
	}

`{`
`"type":"record",`
`"name":"Ingredient",`
`"fields":[`
`{`
`"name":"name",`
`"type":"string"`
`},`
`{`
`"name":"sugar",`
`"type":"double"`
`},`
`{`
`"name":"fat",`
`"type":"double"`
`}`
`]`
`}`
	class Ingredient {
	
	private String name;
	private double sugar;
	private double fat;
	
	public Ingredient() {}
	
	public Ingredient(String name, double sugar, double fat) {
	this.name = name;
	this.sugar = sugar;
	this.fat = fat;
	}
	
	public String getName() {
	return name;
	}
	
	public void setName(String name) {
	this.name = name;
	}
	
	public double getSugar() {
	return sugar;
	}

	public void setSugar(double sugar) {
	this.sugar = sugar;
	}
	
	public double getFat() {
	return fat;
	}
	
	public void setFat(double fat) {
	this.fat = fat;
	}
	
	}

VI. Wykorzystywane struktury:

```
enum TokenType {
    LEFT_BRACE,
    RIGHT_BRACE,
    LEFT_BRACKET,
    RIGHT_BRACKET,
    COMMA,
    COLON,
    STRING,
    NUMBER,
    LITERAL,
    ERROR,
    EOF
}

class Token
{
    private int row;
    private int column;
    private int hashValue;
    private String tokenValue;
    private TokenType tokenType;
}

enum NodeType
{
    ROOT,
    OBJECT,
    ARRAY,
    PAIR,
    NAME,
    VALUE,
    ERROR,
    EOF
}

class Node
{
    string name;
    string value;
    Node parent;
    Node firstChild;
    Node nextSibling;
```

```
    NodeType nodeType;
}
```

VII. Moduły:

a) Analizator leksykalny:
   - pobiera po kolei znaki z pliku tekstowego tworząc z nich token zgodny z gramatyką i zwraca go jako wynik przekazany do parsera.

b) Analizator składniowy wraz z akcjami semantycznymi:
   - porozumiewa się z analizatorem leksykalnym, który przesyła kolejne tokeny. Na ich podstawie tworzy drzewa składające się z obiektów JsonNode.
   - sprawdza poprawność występujących pól z warunkami schematu AVRO: słowa kluczowe, typy prymitywne i złożone.

c) Generator pliku wyjściowego:
   - przekształca powstałą strukturę na plik tekstowy zawierający opis klasy w języku Java.

VIII. Drzewo dokumentu:

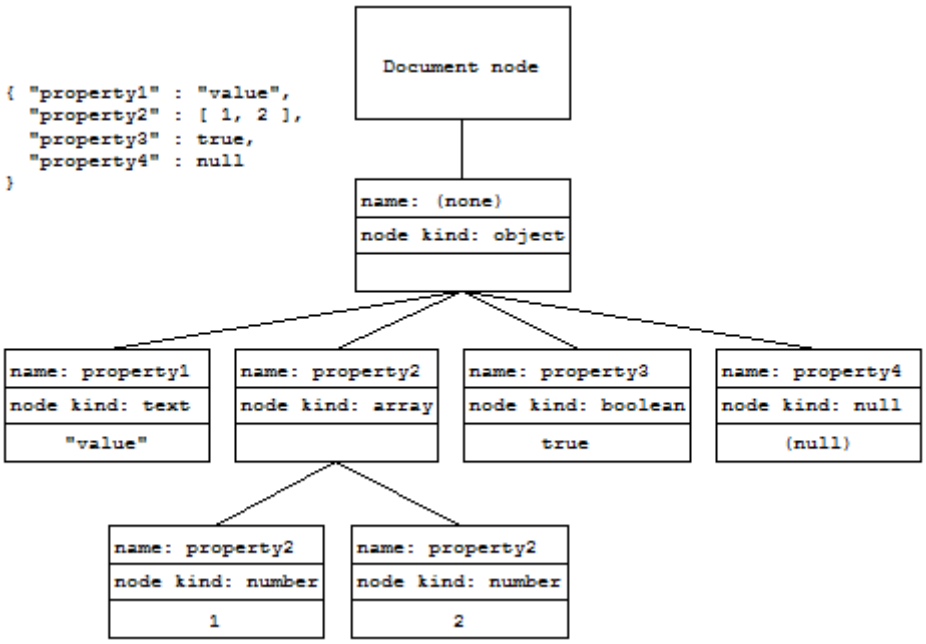

IX. Obsługa sytuacji wyjątkowych:

Błędy w pliku wejściowym powodują wyświetlenie komunikatu o błędzie i przerwanie działania programu. W komunikacie o błędzie wypisuje jaki niepoprawny token otrzymaliśmy oraz miejsce w pliku (numer wiersza i numer kolumny). Przewidywane przypadki:

- InvalidFileException – błąd obsługi pliku,
- InvalidTokenException – konstrukcje niepoprawne leksykalnie,
- UnexpectedTokenException – konstrukcje niepoprawne semantycznie,

- InvalidAvroException – konstrukcje niespełniające warunków schematu AVRO,

X. Przykładowy plik:

- Schemat AVRO w notacji JSON:

```
{
  "type": "record",
  "name": "Movie",
  "namespace": "org.kitesdk.examples.data",
  "fields": [
    {
      "name": "id",
      "type": "int"
    },
    {
      "name": "title",
      "type": "string"
    },
    {
      "name": "releaseDate",
      "type": "string"
    },
    {
      "name": "imdbUrl",
      "type": "string"
    }
  ]
}
```

- Klasa w języku Java:

```
package org.kitesdk.examples.data;

public class Movie {
    private int id;
    private String title;
    private String releaseDate;
    private String imdbUrl;

    public Movie() {}

    public Movie(int id, String title, String releaseDate, String
imdbUrl) {
        this.id = id;
        this.title = title;
        this.releaseDate = releaseDate;
        this.imdbUrl = imdbUrl;
    }

    public int getId() {
        return id;
    }

    public void setId(int id) {
        this.id = id;
```

```
    }

    public String getTitle() {
        return title;
    }

    public void setTitle(String title) {
        this.title = title;
    }

    public String getReleaseDate() {
        return releaseDate;
    }

    public void setReleaseDate(String releaseDate) {
        this.releaseDate = releaseDate;
    }

    public String getImdbUrl() {
        return imdbUrl;
    }

    public void setImdbUrl(String imdbUrl) {
        this.imdbUrl = imdbUrl;
    }

}
```

XI. Literatura:

http://www.ietf.org/rfc/rfc4627.txt - opis notacji JSON.
https://avro.apache.org/docs/current/spec.html - opis schematu AVRO.